

Laboratorium 5

Autorzy: Kosman Mateusz, Ludwin Bartosz

Temat laboratorium:

Celem niniejszego zadania jest analiza numeryczna problemu aproksymacji danych historycznych dotyczących populacji Stanów Zjednoczonych w latach 1900–1980, z zastosowaniem metody najmniejszych kwadratów oraz ekstrapolacji wyników do roku 1990. W sprawozdaniu podejmujemy próbę wyznaczenia optymalnego stopnia wielomianu interpolacyjnego dla badanych danych przy użyciu zarówno empirycznych miar błędu (błąd względny), jak i kryterium informacyjnego Akaikego (AIC_c). Dodatkowo analizie podlega ciągła aproksymacja funkcji $f(x) = \sqrt{x}$ w przedziale $[0, 2]$ przy wykorzystaniu wielomianów Czebyszewa, co pozwala na porównanie efektywności metody analitycznej oraz numerycznych technik aproksymacyjnych.

Treść:

Zadanie 1. Wykonaj aproksymację średniokwadratową punktową populacji Stanów Zjednoczonych w przedziale $[1900, 1980]$ wielomianami stopnia m dla $0 \leq m \leq 6$.

- a. Dla każdego m dokonaj ekstrapolacji wielomianu do roku 1990. Porównaj otrzymaną wartość z prawdziwą wartością dla roku 1990, wynoszącą 248 709 873.
- b. Czy stopień m odpowiadający najmniejszej wartości AIC_c pokrywa się z wartością z poprzedniego podpunktu?

Zadanie 2. Wykonaj aproksymację średniokwadratową ciągłą funkcji $f(x) = \sqrt{x}$ w przedziale $[0, 2]$ wielomianem drugiego stopnia, używając wielomianów Czebyszewa.

Rozwiązanie:

Zadanie 1. a):

Wykonamy aproksymację populacji USA dla różnych stopni wielomianu (od 0 do 6 włącznie). W tym celu użyjemy równania:

$$A^T A c = A^T y \quad (1)$$

gdzie A - macierz Vandermonde'a o $m + 1$ rzędach, c - szukane współczynniki wielomianu, y - wartości populacji w USA w danym roku.

Po obliczeniu współczynników tworzymy wielomian ze wzoru:

$$p(x) = \sum_{j=0}^n c_j x^j \quad (2)$$


gdzie c_j oznacza współczynnik przy j -tym stopniu x , a następnie podstawiamy argument do wielomianu aby ekstrapolować rok 1990. W kodzie uzyskamy ten rezultat za pomocą funkcji *np.polyval*, oraz wykonamy powyższe operacje dla wszystkich wielomianów (ze stopniami od 0 do 6 włącznie).

Następnie dla każdej otrzymanej w ten sposób wartości liczymy błąd względny, otrzymując wartości:

Stopień wielomianu m	Ekstrapolowana wartość dla roku 1990	Błąd względny
0	143369177	0.42355
1	235808109	0.05187
2	254712945	0.02414
3	261439111	0.05118
4	251719359	0.0121
5	259115342	0.04184
6	249510782	0.00322


Tabela 1

Sporządzając wykres stopnia wielomianu od błędu względnego otrzymujemy:



Wykres 1

Wyraźnie widać że wartość z najmniejszym błędem względnym została otrzymana dla stopnia wielomianu równego 6. Potwierdziła to również funkcja *find_smallest_error*. Rysując wykres tego wielomianu otrzymujemy:



Wykres 2

Jak można zauważyć na wykresie, wielomian bardzo dobrze wpasował się zarazem w oryginalne dane, jak i w podaną w zadaniu prawdziwą wartość dla roku 1990.

Zadanie 1. b):

Do wyboru optymalnego stopnia wielomianu można posłużyć się kryterium informacyjnym Akaikego. Jest ono dane wzorem:

$$AIC = 2k + n \ln\left(\frac{\sum_{i=1}^n [y_i - \hat{y}(x_i)]^2}{n}\right) \quad (3)$$

gdzie $k = m + 1$, $y_i = (1, 2, \dots, n)$ oznacza prawdziwą liczbę osób w roku x_i , natomiast $\hat{y}(x_i)$ liczbę osób przewidywaną przez model. Zważywszy jednak na mały rozmiar próbki ($\frac{n}{k} < 40$), należy użyć wzoru z czynnikiem korygującym:

$$AIC_c = AIC + \frac{2k(k+1)}{n-k-1} \quad (4)$$

Korzystając ze wzoru (4) otrzymujemy:

Stopień wielomianu m	0	1	2	3	4	5	6
Wartość kryterium Akaike'a	321.01098	289.05648	279.45337	284.8804	292.67239	319.82799	387.93123

Tabela 2

Najmniejszą wartość kryterium otrzymaliśmy dla $m = 2$, co nie pokrywa się z empirycznie uzyskaną wartością ($m = 6$) w podpunkcie a).

Zadanie 2.

W tym zadaniu do aproksymacji wartości funkcji f wykorzystujemy wielomiany Czebyszewa drugiego stopnia.

Wielomian Czebyszewa dla $x \in [-1, 1]$ definiujemy następująco:

$$T_0(x) = 1,$$

$$T_1(x) = x,$$

$$T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x).$$

Rozważamy jedynie $k \leq 2$, stąd nie korzystamy ze wzoru rekurencyjnego w implementacji.

Iloczyn skalarny dwóch funkcji z wagą definiujemy następująco:

$$\langle f, g \rangle = \int_{-1}^1 w(x)f(x)g(x)dx$$

Wielomiany Czebyszewa są **ortogonalne**, stąd wiemy, że $T_i(x)T_j(x) = 0$ dla $i \neq j$. Dla $i = j$ mamy:

$$i = j = 0: \langle T_i, T_j \rangle = \pi$$


$$i = j \neq 0: \langle T_i, T_j \rangle = \frac{\pi}{2}$$

Dla $\langle f, T \rangle$ mamy $w(x) = \frac{1}{\sqrt{1-x^2}}$.

Współczynniki Czebyszewa wynoszą: $c_k = \frac{\langle f, T_k \rangle}{\langle T_k, T_k \rangle}$

Ostatecznie nasza aproksymacja p wynosi: $p(x) = \sum_{k=0}^2 c_k T_k(x)$

Aproksymacja Czebyszewa prezentuje się następująco względem funkcji f :

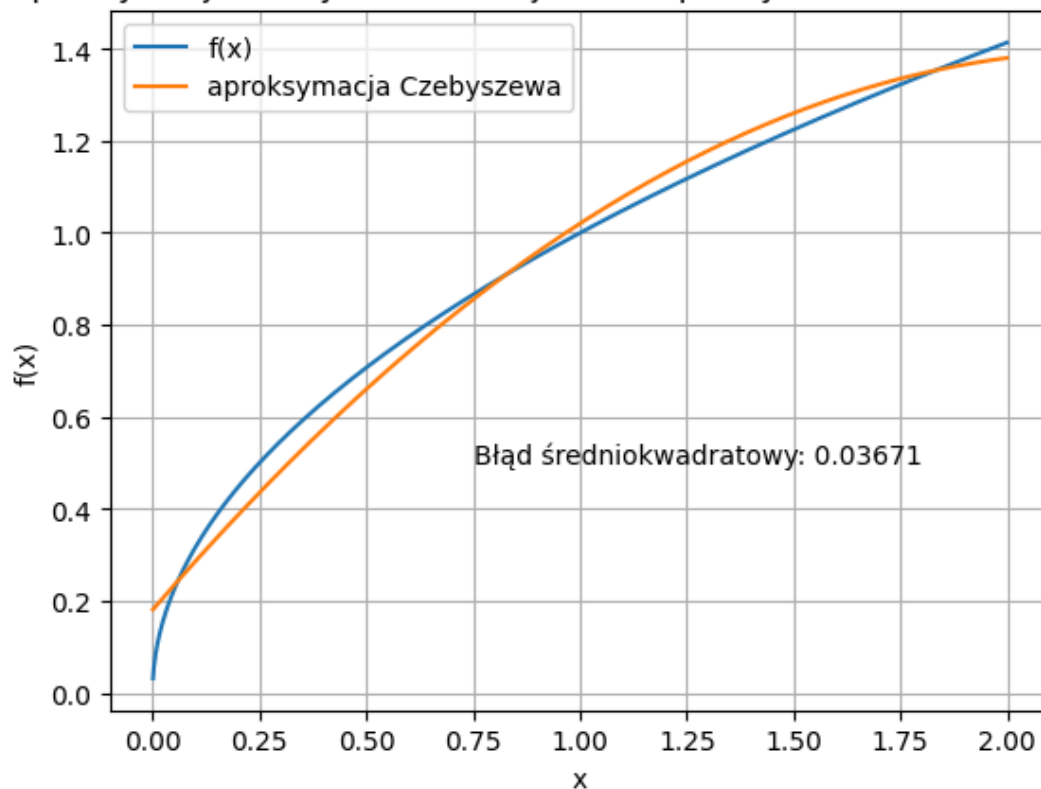


Wykres 3 - Aproksymacja Czebyszewa funkcji $f(x)$

Zad 5 $g(t) = f(t+1) = \sqrt{t+1}$
 $T_0(t) = 1$ $T_1(t) = t$ $T_2(t) = 2t^2 - 1$
 $a_k = \frac{2}{\pi} \int_{-1}^1 \frac{g(t) T_k(t)}{\sqrt{1-t^2}} dt = \frac{2}{\pi} \int_{-1}^1 \frac{(t+1) T_k(t)}{\sqrt{1-t^2}} dt = \frac{2}{\pi} \int_{-1}^1 \frac{T_k(t)}{\sqrt{1-t^2}} dt$
 $a_0 = \frac{2}{\pi} \int_{-1}^1 \frac{1}{\sqrt{1-t^2}} dt = \frac{2}{\pi} [-2\sqrt{1-t^2}]_{-1}^1 = \frac{2}{\pi} [0 + 2\sqrt{2}] = \frac{4\sqrt{2}}{\pi}$
 $a_1 = \frac{2}{\pi} \int_{-1}^1 \frac{t}{\sqrt{1-t^2}} dt = \frac{2}{\pi} [-\frac{1}{2} \sqrt{1-t^2} (t+2)]_{-1}^1 = \frac{4\sqrt{2}}{3\pi}$
 $a_2 = \frac{2}{\pi} \int_{-1}^1 \frac{2t^2-1}{\sqrt{1-t^2}} dt = \frac{2}{\pi} [-\frac{2}{15} \sqrt{1-t^2} (6t^2+8t+1)]_{-1}^1 = \frac{4\sqrt{2}}{15\pi}$

Rysunek 1 - obliczenia współczynników Czebyszewa

Aproksymacja Czebyszewa funkcji $f(x)$ (współczynniki obliczone ręcznie)



Wykres 4 - Aproksymacja Czebyszewa funkcji $f(x)$ (współczynniki obliczone ręcznie)

Widać, że błąd średniokwadratowy dla współczynników obliczonych numerycznie jest wyższy niż dla tych obliczonych analitycznie. Źródłem większego błędu dla współczynników obliczonych numerycznie może być przycięcie dziedziny o 2^{-10} przy jej końcach, co było konieczne ze względu na zerowanie się mianownika funkcji $w(x)$ dla $x \in \{-1, 1\}$.

Wnioski:

- Aproksymacja jest skuteczniejszą techniką niż interpolacja do przewidywania nieznanych wartości. W szczególności jest przydatna, gdy nie zależy nam, aby funkcja aproksymująca przecinała dokładnie zadane punkty, lecz znajdowała się w ich pobliżu.
- Kryterium informacyjne Akaikego daje optymalny, jednak nie zawsze najlepszy stopień wielomianu.
- Do obliczeń wykonywanych na bardzo dużych liczbach lepiej używać typu Double niż Int, aby uniknąć zjawiska przepełnienia (overflow).
- Aproksymacja Czebyszewa jest wydajnym algorytmem (złożoność czasowa $O(nk)$, gdzie n jest liczbą próbek, a k najwyższym stopniem wielomianu Czebyszewa) wyznaczającym aproksymację ciągłą.

- Obliczanie numeryczne całek funkcji dążących do nieskończoności przy krańcach dziedziny wymaga przycięcia tej dziedziny. Skutkuje to jednak mniejszą dokładnością obliczeń względem wyprowadzania całek analitycznie.

Źródła:

- Prezentacje z MS Teams (zespół MOwNiT 2025)
- pythonnumericalmethods.studentorg.berkeley.edu
- https://en.wikipedia.org/wiki/Chebyshev_polynomials